

Understanding Spotify's Data Landscape

Niveau actuel de maturité des données de Spotify et les principaux défis en matière de gouvernance des données

I. Niveau actuel de maturité des données de Spotify

Spotify, en tant que leader mondial du streaming (40 % du marché, présent dans 180 pays), gère une grande quantité de données générées par ses utilisateurs (600 millions) et ses produits (streaming musical, podcast mais aussi livres audio, vidéos éducatives).

Spotify dispose d'une Data Plateforme qui collecte quotidiennement près de 1 400 milliards d'événements.

Les data proviennent des activités des utilisateurs sur les différents services (des milliers) et des informations récoltées sur lui depuis son inscription.

L'intégration, le traitement (38 000 pipelines actifs pour des tâches horaires et quotidiennes) et l'utilisation de la data (Google/BigQuery) est en temps réel.

Des contrôles d'accès et des politiques de conservation sont en place pour gérer les stockages et se conformer aux réglementations.

Après traitement, cette donnée est exploitée pour :

- Fournir des services personnalisés aux utilisateurs, comme les recommandations musicales mais aussi des publicités ciblées.
- Expérimenter de nouveaux développements. La plateforme Confidence (test A/B) permet d'expérimenter en continue. Elle s'ouvre aussi aux développeurs hors Spotify et devient un axe de développement commercial.
- Orienter les stratégies de Spotify et prendre les décisions.

L'infrastructure de données de Spotify est sophistiquée et associe des data lakes, des relational databases et des systèmes de stockage basés sur le cloud.

Le graphique ci-dessous représente la capacité de Spotify à collecter, gérer, analyser et utiliser les données de manière efficace, efficiente et légale.

Schéma de maturité des données de Spotify



Spotify est une entreprise dont l'activité est basée sur la bonne gestion et une utilisation optimale de la data. Le niveau de maturité data est à ce jour élevé (proche de 4/5) et à sans doute, par le passé, été proche de 5 (efficacité maximale).

Le développement rapide de Spotify, géographiquement et dans son offre, dans un environnement technologique en constante transformation impose à Spotify de repenser en permanence sa gestion data afin de rester le leader dans son domaine et poursuivre son développement.

Au fil de son développement, des failles apparaissent dans sa gestion des données, d'où la dégradation de sa note.

II. Principaux défis en matière de gouvernance des données

1. Qualité et accessibilité des données

Les sources de données sont de plus en plus nombreuses et nécessitent un traitement de plus en plus rapide afin d'être au plus près des besoins en temps réel.

a. Silos de données et fragmentation

Certains services gèrent une partie de leurs bases de données de façon indépendante. Cette fragmentation de la data empêche d'obtenir une vue d'ensemble nécessaire à une analyse complète.

b. Accessibilité et intégration des données

La culture d'expérimentation et d'utilisation maximale de la data via l'IA et le big data nécessite un accès rapide à des données de qualité pour optimiser les résultats.

L'obsolescence, l'inexactitude ou l'incomplétude de la data base peut amener à la livraison de service erronés aux utilisateurs, à la perte d'opportunités commerciales ou d'optimisation organisationnelle ainsi qu'entraîner de mauvaises décisions dans le développement ou la stratégie.

2. Gestion de la data : conformité et éthique

a. Conformité réglementaire

Le développement géographique de Spotify multiplie les réglementations locales à respecter, complexifiant la gestion des données.

Dans un même temps, les différentes réglementations évoluent et de nouvelles obligations peuvent apparaître.

De même, de nouvelles fonctionnalités Spotify peuvent rendre les consentements des utilisateurs obsolètes, nécessitant une actualisation.

b. Éthique

Au-delà du respect des réglementations locales, Spotify se doit de disposer d'une politique cohérente au niveau mondiale.

Les utilisateurs souhaitent de plus en plus être acteur de la gestion de leurs données et demandent un consentement éclairé et explicite, nécessitant transparence et gestion responsable des données.

Une perte de confiance des utilisateurs, que ce soit pour non-respect d'un règlement ou par opacité des utilisations des données, peut être dévastateur pour le modèle de Spotify, dont le fonds de commerce est la donnée collectée auprès des utilisateurs.

Pour gérer ces défis, la data security doit évoluer pour répondre aux besoins de volumes élevés. Les risques doivent être identifiés et monitorés à chaque étape. Les contrôles d'accès et les politiques de conservation doivent également évoluer pour gérer les coûts de stockage et se conformer en permanence aux réglementations.

La réussite de la gouvernance des données repose sur la culture de la donnée au sein de Spotify. L'implication de chaque collaborateur est indispensable, car la gouvernance est à la fois technique et humaine.